

Análisis de Series de Tiempo II

MSc. Fernando Silva

fernandosilva.clases@gmail.com



Análisis de Series de Tiempo II

Fundamentos del Forecasting Moderno y Representación Temporal

MSc. Fernando Silva



Organización

Descripción general

El curso aborda técnicas modernas de forecasting temporal utilizando Deep Learning y Machine Learning avanzado, cubriendo desde la representación de series temporales y modelos baseline hasta arquitecturas profundas modernas, transformers temporales, forecasting probabilístico y sistemas de forecasting en producción.

Distribución de notas

La calificación final se calculará como el promedio de las siguientes actividades:

- Tarea 1
- Tarea 2
- Tarea 3

Modalidad de trabajo: Las tareas podrán realizarse de manera individual o en grupos de 2 a 3 integrantes.

Material


Todo el contenido de la materia estará disponible en un repositorio de GitHub, donde se publicarán los materiales. Las tareas deberán ser entregadas a través de Google Forms.

Organización

Sílabo

Clase	Temario
1	Fundamentos del Forecasting Moderno y Representación Temporal
2	Baselines Modernos y Feature Engineering Temporal
3	Forecasting Secuencial con RNN, LSTM y GRU
4	Forecasting Multivariado y Global Forecasting Models
5	Temporal Convolutional Networks y Arquitecturas Modernas
6	Transformers para Series Temporales
7	Forecasting Probabilístico y Modelado de Incertidumbre
8	Forecasting en Producción y Sistemas Reales

Agenda



Series de Tiempo

Series de Tiempo

Definición

Una serie de tiempo es una secuencia de observaciones o mediciones registradas en diferentes instantes de tiempo. Formalmente:



X es la variable observada

$X(t_i)$

t_i es el instante temporal (segundos, días, meses, etc)

Ejemplos:

- Precio diario del dólar
- Temperatura cada hora
- Señal de audio
- Tráfico de red
- ECG (electrocardiograma)



Series de Tiempo

N (muestras) = cuántos instantes observaste.
D (dimensiones) = cuántas variables mides en cada instante.

En la práctica, se trata de una matriz de números reales de tamaño $D \times N$, donde D es el número de dimensiones y N el número de muestras.

- Muestra n :

n	0	1	2	3	4	5	6
-----	---	---	---	---	---	---	---

- Valor de serie de tiempo $x[n]$:

$x[n]$	0.7	0.2	0.8	0.9	0.3	0.2	0.7
	0.4	0.1	0.6	0.2	0.5	0.6	0.3

- Timestamps $t[n]$:

el tiempo en el que se tomó cada muestra

$t[n]$	16:30:01	16:30:23	16:31:43	16:32:38	16:33:06	16:33:16	16:33:56
--------	----------	----------	----------	----------	----------	----------	----------

Δt no son constantes

Series de Tiempo


Características

- **Mediciones etiquetadas en el tiempo**

Una serie temporal consiste en datos asociados a un instante de tiempo:

$$X_1, X_2, X_3, \dots, X_n$$

A veces estas observaciones pueden contener errores de medición (observation errors) o ruido.



Ejemplo:

- **Temperatura real:** 25.0 °C
- **Sensor mide:** 25.2 °C

Ese 0.2 es error de observación.

Series de Tiempo

Características

- **No son i.i.d**

Machine Learning (ML)

En ML clásico se suele asumir que los datos son i.i.d. es decir Independent and Identically Distributed (Independientes y Proviene de la misma distribución)

Series de Tiempo

En series de tiempo esto generalmente **NO** se cumple, porque el valor actual depende de valores pasados:

$$P(X_t | X_{t-1}, X_{t-2}, \dots)$$

Series de Tiempo

Características

- **Datos secuenciales**


Cada punto está ordenado temporalmente:

$$X_1 \rightarrow X_2 \rightarrow X_3 \rightarrow X_4$$

La secuencia importa, si mezclamos el orden perdemos la información.

Ejemplo:

- **Audio:** si re-ordenamos las muestras, el sonido se destruye.




Referencia: <https://medium.com/@kyrie-c-jones/music-as-a-time-series-with-python-85a21007ae8d>


Series de Tiempo

Ejemplos


(a) Daily average number of truck manufacturing defects




(b) Yearly U.S. tobacco production



(c) Quarterly U.S. beer production



(d) Contaminated blowfly data




Series de Tiempo

Anotaciones y el Tiempo

- **Anotaciones**

A diferencia de tareas básicas de procesamiento de imágenes (por ejemplo, clasificación de gatos y perros), la anotación de series de tiempo suele requerir experiencia especializada.



Contexto típico de datos de Series de Tiempo:

- Datos ruidosos y de baja calidad.
- Un número reducido de señales anotadas con etiquetas ambiguas o poco definidas.

- **Tiempo**

La diferencia entre datos regulares y de series de tiempo es la noción de secuencia y cronología.



Análisis de Series de Tiempo

Definición

- Es la tarea de extraer información estadística y resúmenes significativos a partir de datos organizados en orden cronológico.
- Se realiza tanto para comprender y diagnosticar comportamientos pasados como para predecir comportamientos futuros.



Representación Temporal

Representación Temporal

Univariantes vs Multivariantes

Univariantes

Registran una sola variable a lo largo del tiempo.

- Son más sencillas de modelar e interpretar, y funcionan bien cuando la variable objetivo se explica por su propio pasado.
- Sus modelos clásicos son ARIMA, ETS y Prophet.

Index	Variable 1	Target Variable
..	..	...
..	..	..

Multivariantes



Registran dos o más variables simultáneamente.

- El gran beneficio es que permiten capturar relaciones cruzadas entre variables, es decir, cómo el comportamiento de una afecta a otra.
- Los modelos más usados son VAR (Vector Autoregression), LSTM y redes neuronales temporales.

Index	Variable 1	Variable 2	Variable n	Target Variable
..	..	..	..	...
..	..	..	..	..

Representación Temporal

Series Univariadas vs Multivariadas




Representación Temporal

Panel data (múltiples series)

El panel data (o datos de panel) es una estructura que combina dos dimensiones al mismo tiempo: entidades y tiempo.


Lo que lo distingue de una serie de tiempo simple es que se tiene múltiples series corriendo en paralelo, una por cada entidad, todas sobre el mismo eje temporal.



Representación Temporal

Panel data (múltiples series)

Evolución del crecimiento en varios países, 1913-1990



Referencia: Wikipedia, PIB per cápita 1920-1990


Representación Temporal

Event-based temporal data

En los datos basados en eventos, el tiempo es continuo y solo se registra algo cuando el mundo lo "decide".

Ejemplos:

- Clicks en e-commerce (logs web)
- Transacciones financieras
- Latidos del corazón (ECG)
- Sismos, llamadas telefónicas



Representación Temporal

Regular vs Irregular

Δt es el intervalo de tiempo entre dos observaciones consecutivas de la serie

Regular

- Una serie regular la muestreamos a intervalos fijos: cada hora, cada día, cada minuto.
- Eso nos da un índice entero limpio y acceso directo a toda la maquinaria clásica: FFT para frecuencias, ARIMA, STL para descomposición estacional, autocorrelación, etc.

Irregular

- Es el mismo fenómeno de fondo, pero observado a tiempos arbitrarios (Δt no constante).
- El problema: la mayoría de los modelos asumen Δt fijo.
- Dos salidas: regularizar a una grilla fija (imputar/resamplear) y usar modelos clásicos, o usar modelos que aceptan tiempo continuo (Neural ODE, o Δt como feature).

Ejemplos:


- Temperatura horaria
- Precio de cierre diario

Ejemplos:

- Historial clínico paciente
- Lecturas de sensor IoT

Representación Temporal

Regular vs Irregular



Representación Temporal

[LINK](#)




Conversión a Problema Supervisado

Conversión a Problema Supervisado

Introducción

- ML/DL espera pares (X, y)
- ¿Cómo convertimos una secuencia en eso sin romper el orden?
 - X: input window
 - y: forecast horizon


Time series



Conversión a Problema Supervisado


Sliding Window

Sliding Window



Input Window

Forecast Horizon




Input Window

Forecast Horizon



Input Window

Forecast Horizon



Input Window

Forecast Horizon

Conversión a Problema Supervisado

Rolling windows

Supongamos que tenemos la siguiente serie:

10, 20, 30, 40, 50 y definimos ventana de tamaño **3**

Sliding Window

Generamos muestras supervisadas (X, y)

$X = [10, 20, 30], y = 40$

$X = [20, 30, 40], y = 50$

**sliding lo usamos para armar pares
(X, y)**

Rolling Window

Calculamos una estadística que “rueda” sobre la serie. Misma ventana, pero la salida es un solo número agregado por posición

$\text{media}(10, 20, 30) = 20$

**rolling lo usamos para resumir
(feature engineering)**

Conversión a Problema Supervisado

Expanding windows

- La ventana de input **crece**, el horizonte es fijo.
- Esto reaparece en validación (walk-forward).



Tipos de Forecasting

One-Step Ahead vs Multi-Step Ahead

La diferencia fundamental es el horizonte H : cuántos pasos futuros quieres predecir de una sola vez.

One-Step Ahead ($H=1$)

- El modelo solo predice el siguiente valor. No hay forma de que el error se propague porque no hay pasos encadenados.
- Ideal cuando se necesita respuesta inmediata y precisa, como detección de anomalías en tiempo real o control de procesos industriales.



■ Actual Data
■ Current Forecast
■ Previous Forecast
□ Future Data

Multi-Step Ahead ($H>1$)

- Predice varios pasos futuros, y aquí aparece el problema central: la acumulación de error.
- Cuanto más lejos en el horizonte, mayor la incertidumbre.



Tipos de Forecasting


Recursive forecasting

Recursive

- El modelo predice el día siguiente, luego usa esa predicción para predecir el que sigue.
- Como un teléfono descompuesto: cada vez que se repite el mensaje, se distorsiona un poco más.

Recursive forecasting strategy

$$e_{t+j} = \text{actual}_{t+j} - \text{forecast}_{t+j}$$




Direct

- Se tiene un modelo distinto para cada horizonte. Uno entrenado para predecir "3 días adelante", otro para "7 días adelante", etc.
- Cada uno va directo a su objetivo sin depender de predicciones anteriores.

Direct forecasting strategy

$$e_{t+h} = \text{actual}_{t+h} - \text{forecast}_{t+h}$$




Tipos de Forecasting

MIMO

- La tercera estrategia multi-step. Un solo modelo que, a partir de la ventana de input, emite el vector completo del horizonte de una sola pasada.
- No hay realimentación (a diferencia de recursive), no acumula error.
- No es un modelo por horizonte (a diferencia de direct) un solo entrenamiento, y preserva la dependencia conjunta entre los pasos futuros: los predice juntos, no de forma independiente.

Limitación: el horizonte H queda fijo en el entrenamiento (es la dimensión de salida).



Conversión a Problema Supervisado


[LINK](#)



Introducción al Forecasting Moderno

Introducción al Forecasting Moderno


Forecasting clásico vs ML/DL forecasting



Introducción al Forecasting Moderno


Clásico Estadístico (ARIMA, ETS, Theta, Prophet)

Modelo generativo
explícito, una serie a la vez,
funciona con pocos datos.




ML tabular (LightGBM/XGBoost sobre features)

La serie se vuelve tabla, es
global, depende de feature
engineering manual, y suele
ser el elegido para
producción.



Deep Learning (RNN/LSTM/TCN/ Transformers)

Aprende la representación,
global, escala con datos,
caja negra.



Introducción al Forecasting Moderno

Forecasting Local vs Global

Forecasting Local

Un modelo por serie.

- Cada serie tiene sus propios parámetros.
- Clásico en estadística tradicional.
- Modelos típicos: ARIMA, Exponential Smoothing (ETS), Theta

Captura perfectamente la dinámica de cada serie

No escala, no aprovecha patrones entre series, falla con series cortas

Forecasting Global

Un solo modelo para todas las series.


- Aprende patrones compartidos entre series. Dominante en ML moderno.
- Modelos típicos: LightGBM, XGBoost, LSTM, N-BEATS, TFT

Escala a miles de series, funciona bien con series cortas, transfiere información entre series

Puede subajustar series con comportamiento muy atípico

Introducción al Forecasting Moderno

Forecasting Local vs Global



Introducción al Forecasting Moderno

¿Qué supuestos relaja lo moderno?

Estacionariedad

ARIMA te obliga a diferenciar,
boosting/Deep Learning no la
exigen explícitamente.

Linealidad

ARIMA es lineal en los lags,
boosting/Deep Learning capturan
no-linealidades.

Forma de tendencia/estacionalidad

ETS la modela a mano,
moderno la aprende.

El precio

Moderno pide más datos y pierde
interpretabilidad.

Introducción al Forecasting Moderno

¿Cuándo gana cada uno?

Pocas series / series cortas /
poco dato

Clásico o Boosting va bien
Deep Learning va mal

Muchas series con patrones
compartidos

Global (ML/DL) va bien

Se necesitan intervalos y
trazabilidad

Clásico va bien

Dependencias largas, no lineales,
muchos datos

Deep Learning va bien

Introducción al Forecasting Moderno

Forecasting point-based vs probabilístico

Forecasting Point-based

Esto responde "¿cuánto?" con un solo número.

- El modelo aprende a minimizar el error promedio (MAE, RMSE, MAPE).
- Es lo más común y fácil de comunicar, pero descarta toda información sobre incertidumbre.

Simple e interpretable

Fácil de comunicar

Ignora la incertidumbre

No sirve para gestión de riesgo

Forecasting Probabilístico

Esto responde "¿cuánto, y con qué certeza?" entregando una distribución completa.

- En lugar de optimizar el error, el modelo aprende a calibrar cuantiles: que el cuantil 80% realmente contenga el valor real el 80% de las veces.

Captura incertidumbre real


Permite optimizar decisiones

Más complejo de modelar

Más difícil de comunicar

Introducción al Forecasting Moderno

Forecasting point-based vs probabilístico



Introducción al Forecasting Moderno


[LINK](#)



Leakage Temporal

Leakage



Idea



Leakage Temporal

Leakage por Escalado

- Ajustar el escalador (μ , σ , min, max) sobre datos que incluyen el futuro filtra información del test al train.
- μ y σ son estadísticos *globales*: si se calculan sobre train+test, cada valor de train queda normalizado "sabiendo" la distribución futura.
- Regla: fit solo en train; transform en train y test con esos parámetros. En validación temporal, re-ajustar en cada fold con su pasado.




Leakage Temporal

Leakage por Engineered Features

- Una feature filtra el futuro cuando su cálculo usa observaciones posteriores al instante que describe.

Toda feature en t debe ser función solo del pasado, $f_t = g(x_1, \dots, x_t)$ no $t+1, t+2, \dots$

- Aunque usemos ventana hacia atrás, si calculamos la feature antes de separar los folds, la media móvil cruza la frontera train/test (sus primeros valores de test usan puntos de train y viceversa). El feature engineering también debe respetar el corte.



t es el origen de forecast (último dato conocido) y el target cae en $t+1$ o después. Por eso usar hasta x_t ($\leq t$) es legal

Leakage Temporal

[LINK](#)




Validación Temporal

Validación Temporal

Holdout Temporal


- **El split correcto más simple:** respeta el orden. Train es primer tramo (pasado), test es último tramo (futuro). Sin shuffle.
- **Contraste con K-fold aleatorio:** barajar mete filas del futuro en el train (entrenás con diciembre para predecir junio), leakage garantizado.
- **Limitaciones:** una sola estimación, alta varianza; el test cubre un único período que puede ser atípico (ej. solo una temporada alta).



Validación Temporal

Walk-forward

- **En vez de un solo corte, avanza el origen:** entrenamos con el pasado, evaluamos en el bloque siguiente, y repetimos moviendo hacia adelante.
- **Cada fold cumple:** todo el train es anterior a todo el test.
- **Ventaja sobre holdout:** múltiples estimaciones, error medio y su varianza, evaluado sobre distintos regímenes.
- El train de cada fold es una ventana fija (deslizante) que avanza.




E (Embargo) es la zona de descarte entre train y test para que ninguna ventana de input cruce el corte

Validación Temporal

Expanding Window

- Variante de walk-forward donde el train crece en cada fold (nunca descarta el pasado).
- Rolling (tamaño fijo) vs expanding (creciente):
 - Expanding si los patrones viejos siguen valiendo, más datos, mejor.
 - Rolling si hay concept drift / cambio de régimen, el pasado lejano estorba, mantiene la ventana reciente.



Validación Temporal

[LINK](#)



Resumen Clase 1

[LINK](#)



Resumen

Una serie de tiempo no es un dataset común.

No es i.i.d. y el orden es información: si lo mezclas, lo perdés.

Primero la representación, después el modelo

Identificar la estructura define qué modelos tenemos disponibles

Para usar ML/DL hay que convertir la secuencia a pares (X, y)

Sin romper el orden, con sliding window.
Definimos la ventana de input y horizonte H.

Clásico modela una serie, moderno aprende de muchas.

ARIMA/ETS vs LSTM/N-BEATS/TFT.

El leakage es el enemigo silencioso

Infla las métricas y casi no se ve.

Validación temporal: jamás shuffle

Toda métrica se compara contra un baseline naive.

Esto lo veremos la siguiente clase.